

机器学习降维方法全解：数学原理与关键应用指南

在机器学习中，降维技术是处理高维数据的核心工具。本文系统梳理了六种主流降维方法，从线性模型到非线性深度学习架构，深入剖析其数学本质并揭示算法设计的关键思考逻辑。通过对比不同方法的适用场景与限制条件，为实际应用提供科学选择依据。

线性降维方法体系

主成分分析（PCA）：方差最大化的正交投影

给定中心化数据集

$$X \in \mathbb{R}^{n \times d}$$

，PCA通过寻找正交投影矩阵

$$W \in \mathbb{R}^{d \times k}$$

将数据映射到低维空间，其优化目标为最大化投影后数据的方差：

$$\max_W \text{tr}(W^T \Sigma W) \quad \text{s.t.} \quad W^T W = I$$

其中协方差矩阵

$$\Sigma = \frac{1}{n} X^T X$$

。通过拉格朗日乘数法可推导出该问题等价于求解

Σ 的前k大特征值对应的特征向量^[1]。

关键洞见：方差最大化保证了投影方向包含最大信息量。这与信息论中的熵最大化原则内在一致，使得PCA成为无监督降维的基准方法。

实施步骤：

- 数据中心化处理
- 计算协方差矩阵
- 特征值分解获取主成分
- 选择累计贡献率达标的成分

应用局限：仅能捕获线性结构，对非线性流形数据效果受限。此时应考虑自编码器等非线性方法^[2]。

线性判别分析（LDA）：类间分离与类内紧致

针对分类任务，LDA优化目标为最大化类间散度与类内散度的比值：

$$\max_W \frac{\text{tr}(W^T S_b W)}{\text{tr}(W^T S_w W)}$$

其中类间散度矩阵

$$S_b = \sum_{i=1}^c N_i (\mu_i - \mu)(\mu_i - \mu)^T$$

，类内散度矩阵

$$S_w = \sum_{i=1}^c \sum_{x \in C_i} (x - \mu_i)(x - \mu_i)^T$$

。通过广义特征值分解求解

$$S_b W = \lambda S_w W$$

得到投影矩阵^[3]。

维度限制：LDA最大降维维度为

$$c-1$$

，其中 c 为类别数。这是因为

$$S_b$$

的秩不超过

$$c-1$$

，超过该维度的特征值为零^[3]。

实践要点：

- 需满足类内协方差同质性假设
- 当特征维度 d 远大于样本数 n 时，需先进行PCA预处理
- 在面部识别等小样本分类任务中表现突出

距离保持型降维范式

多维尺度分析（MDS）：距离矩阵的几何重构

给定距离矩阵

$$D \in \mathbb{R}^{n \times n}$$

，MDS通过求解内积矩阵

$$B = -\frac{1}{2}HDH$$

（ H 为中心化矩阵），进行特征分解

$$B = V\Lambda V^T$$

，取前 k 大特征值对应的特征向量得到低维嵌入

$$Y = V_k \Lambda_k^{1/2}$$

^[4]。

数学本质：将欧氏距离转换为内积空间表示，通过谱分解保持距离不变性。该方法适用于任意距离度量，但计算复杂度为 $O(n^3)$ ，限制了大样本应用。

改进方向：

- 经典MDS仅适用于欧氏距离
- 非度量MDS可处理任意相异性度量
- 与Isomap结合可保持测地距离

非线性降维技术前沿

自编码器：深度非线性特征学习

自编码器由编码器 f_θ

$f_\theta: \mathbb{R}^d \rightarrow \mathbb{R}^k$
和解码器

$g_\phi: \mathbb{R}^k \rightarrow \mathbb{R}^d$ 构成，通过最小化重构误差：

$$\min_{\theta, \phi} \frac{1}{n} \sum_{i=1}^n \|x_i - g_\phi(f_\theta(x_i))\|^2$$

瓶颈层维度 k 决定降维程度。深度结构使其能学习复杂非线性映射，在图像降维任务中显著优于线性方法^[2]。

变分自编码器（VAE）引入概率框架，假设潜在变量 z

$z \sim \mathcal{N}(0, I)$ ，通过证据下界（ELBO）优化：

$$\mathcal{L}(\theta, \phi) = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] - D_{KL}(q_\phi(z|x)||p(z))$$

该框架支持生成式降维，在药物发现等领域展现独特价值^[2]。

流形学习双雄：t-SNE与UMAP

t-SNE通过保持高维空间与低维空间的概率分布相似性进行可视化：

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)}$$
$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}}$$

最小化KL散度 $\sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$

实现降维。其突出优势在于保留局部结构，但计算复杂度达

$O(n^2)$ [5]。

UMAP基于代数拓扑理论，定义高/低维空间相似度：

$$w_{ij} = \exp \left(- \frac{d(x_i, x_j) - \rho_i}{\sigma_i} \right)$$
$$v_{ij} = (1 + a \|y_i - y_j\|^{2b})^{-1}$$

通过交叉熵损失优化嵌入结果。相比t-SNE，UMAP在保持全局结构方面更优，且计算效率提升显著 [5]。

方法选择决策框架

| 维度特征 | 推荐方法 | 数学依据 |
|-------|------------|-------------|
| 线性结构 | PCA | 协方差谱分析 |
| 监督分类 | LDA | 费舍尔判别准则 |
| 距离保持 | MDS | 内积矩阵分解 |
| 高维可视化 | t-SNE/UMAP | 概率分布匹配 |
| 特征生成 | VAE | 变分推断框架 |
| 大规模数据 | 增量PCA/UMAP | 随机SVD/近似最近邻 |

实践建议：

- 1. 探索性分析优先使用PCA/t-SNE
- 2. 分类任务结合LDA与树模型
- 3. 生成任务必选VAE架构
- 4. 时序数据考虑LLE/Isomap

数学基础补充

特征分解：矩阵

A

的特征方程

$Ax = \lambda x$

解的存在性由特征多项式

$\det(A - \lambda I) = 0$ 保证。在降维中，主成分方向对应协方差矩阵的最大特征值方向。

KL散度：衡量概率分布差异的非对称度量：

$$D_{KL}(P||Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}$$

在t-SNE中驱动低维分布逼近高维结构。

流形假设：高维数据通常分布在一个低维流形上，这为非线性降维提供了理论依据。UMAP通过局部连通性和一致邻域图实现流形结构的保持。

理解这些降维方法的内在联系与本质差异，需结合具体数据特性与任务目标进行方法选型。随着图神经网络与对比学习的发展，动态降维与语义保持将成为新的研究方向。

✱

1. https://blog.csdn.net/qq_30841655/article/details/106955674
2. https://blog.csdn.net/qq_41739364/article/details/135144378
3. https://blog.csdn.net/weixin_46564151/article/details/129353543
4. <https://www.imooc.com/article/267075>
5. <https://hackmd.io/@YungHuiHsu/rk-G8BpBT>